Machine Learning per La Certificazione della Qualità Vinicola

ANALISI CHIMICA AVANZATA E CLASSIFICAZIONE PREDITTIVA PER IL CONTROLLO DELLA FILIERA PRODUTTIVA

Progetto di:
Matteo Mallia

Indice

01 Introduzione e Business Case

02 Analisi Esplorativa (EDA)

03 Preprocessing e Preparazione

04 Sviluppo Modelli (SVM & Random Forest)

05 Analisi Comparativa dei Risultati

06 Simulatore Interattivo di Laboratorio

07 Conclusioni e Sviluppi Futuri

Dataset:
Scikit - Learn Wine Dataset
(Analisi Chimiche di Vini Italiani)

Obiettivo Aziendale

Supportare un'azienda di produzione vinicola a basso impatto ambientale nell'automazione del controllo qualità

Task:
Identificare la tipologia di vino (3 classi) tramite 13 analisi chimiche

Valore:
Riduzione degli errori umani e certificazione oggettiva della provenienza

Analisi Esplorativa

L'analisi preliminare ha rivelato che ogni tipologia di vino ha parametri distintivi:

- **Insight:** Alcol e Flavonoidi sono forti discriminanti tra le classi
- **Correlazioni:** Individuata alta correlazione tra fenoli e flavonoidi (0.86)

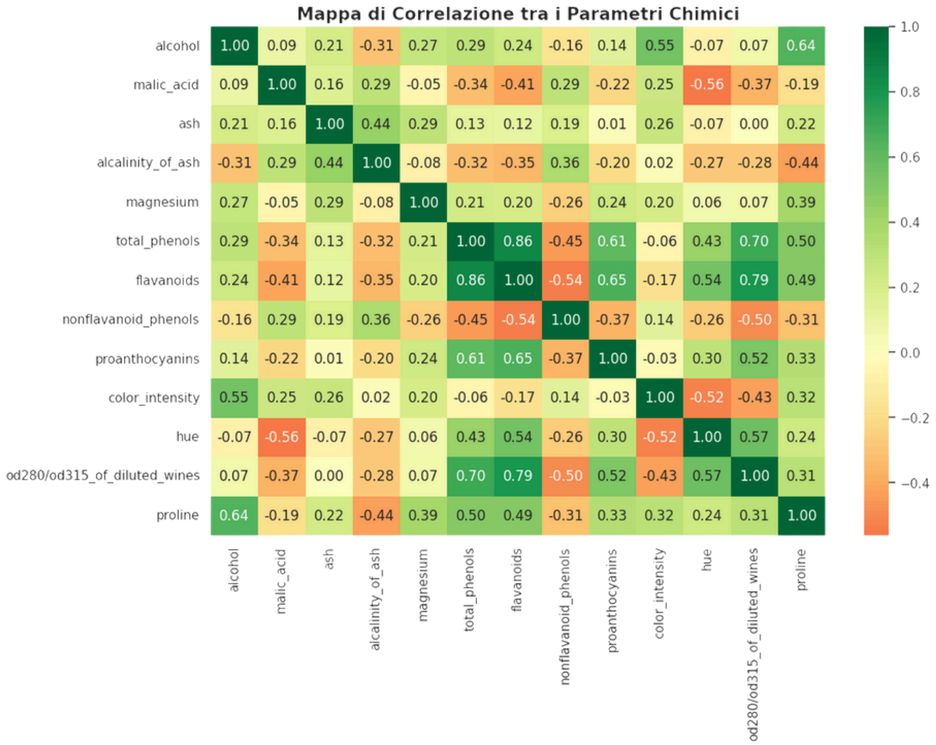

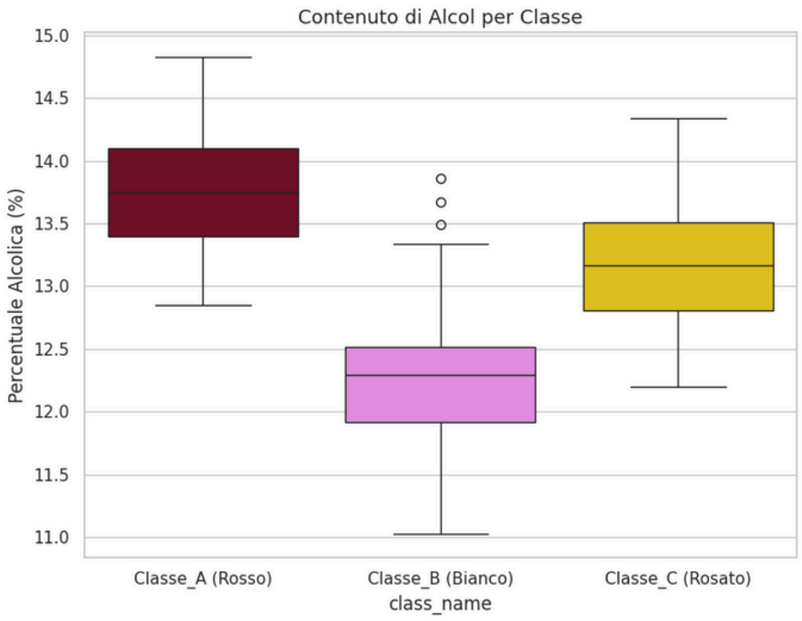

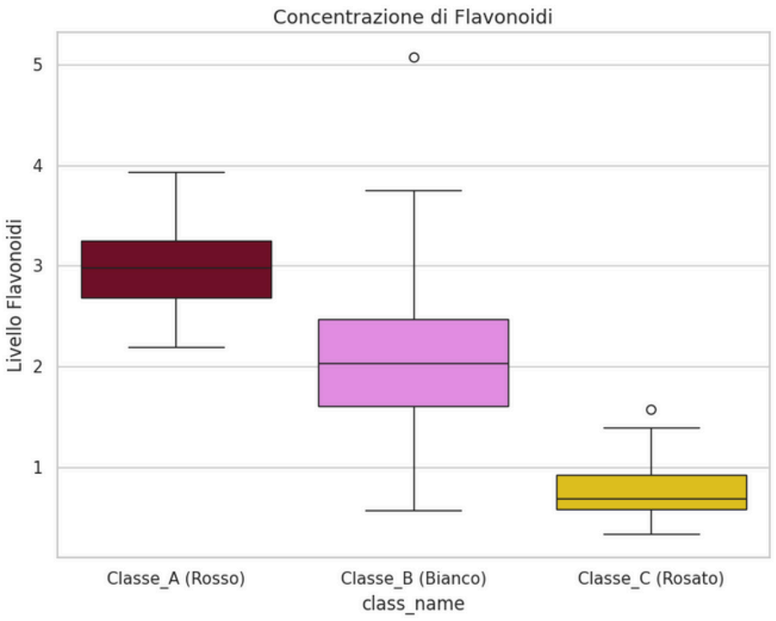

Preprocessing dei Dati

Split Stratificato

- **Perché:** In un dataset di dimensioni contenute, una suddivisione casuale standard rischierebbe di escludere o sottorappresentare una delle tre classi nel set di test
- **Tecnica:** Si è utilizzato lo Stratified Shuffle Split. Questo garantisce che la distribuzione delle classi rimanga identica tra Training (70%) e Test Set (30%)
- **Vantaggio:** Il modello viene valutato su uno specchio fedele della realtà produttiva, evitando che le metriche di performance siano distorte da una distribuzione squilibrata

StandardScaler

- **Logica:** Molti parametri chimici hanno unità di misura e ordini di grandezza differenti;
- **Necessità Matematica:** La SVM calcola la distanza euclidea tra i punti; senza scalatura, le variabili con valori numerici più alti dominerebbero il calcolo
- **Risultato:** Portando ogni feature a media 0 e varianza 1, abbiamo garantito che ogni componente chimico contribuisca con lo stesso peso decisionale alla classificazione finale

Integrità

- **Protocollo:** Per garantire una valutazione imparziale, lo scaler è stato istruito esclusivamente sui dati di addestramento
- **Prevenzione:** La trasformazione del Test Set è avvenuta usando i parametri (media e deviazione standard) derivati dal Training Set
- **Motivazione:** Questo evita il data leakage: il modello non deve avere alcuna promozione sulla distribuzione dei dati di test. In questo modo, simuliamo perfettamente l'arrivo in laboratorio di un vino mai analizzato prima

Capping

- **Neutralizzazione dei valori estremi:** I valori che superano determinate soglie vengono ricondotti a tali limiti. Questo impedisce che singole misurazioni anomale abbiano un peso sporporzionato
- **Preservazione della numerosità campionario:** Il capping permette di mantenere tutti i 178 campioni del dataset
- **Aumento della robustezza del modello:** Il capping stabilizza l'addestramento. Particolarmente utile per la SVM, che si basa sulle distanze geometriche.

Modello A: Support Vector Machine (SVM)

Classificazione tramite Massimizzazione del Margine

- **Tecnica:** Ottimizzazione tramite GridSearchCV e 5 - Fold Cross - Validation
- **Iperparametri:** Selezionato Kernel RBF con C = 1
- **Performance:** Accuratezza sul test set del 98%

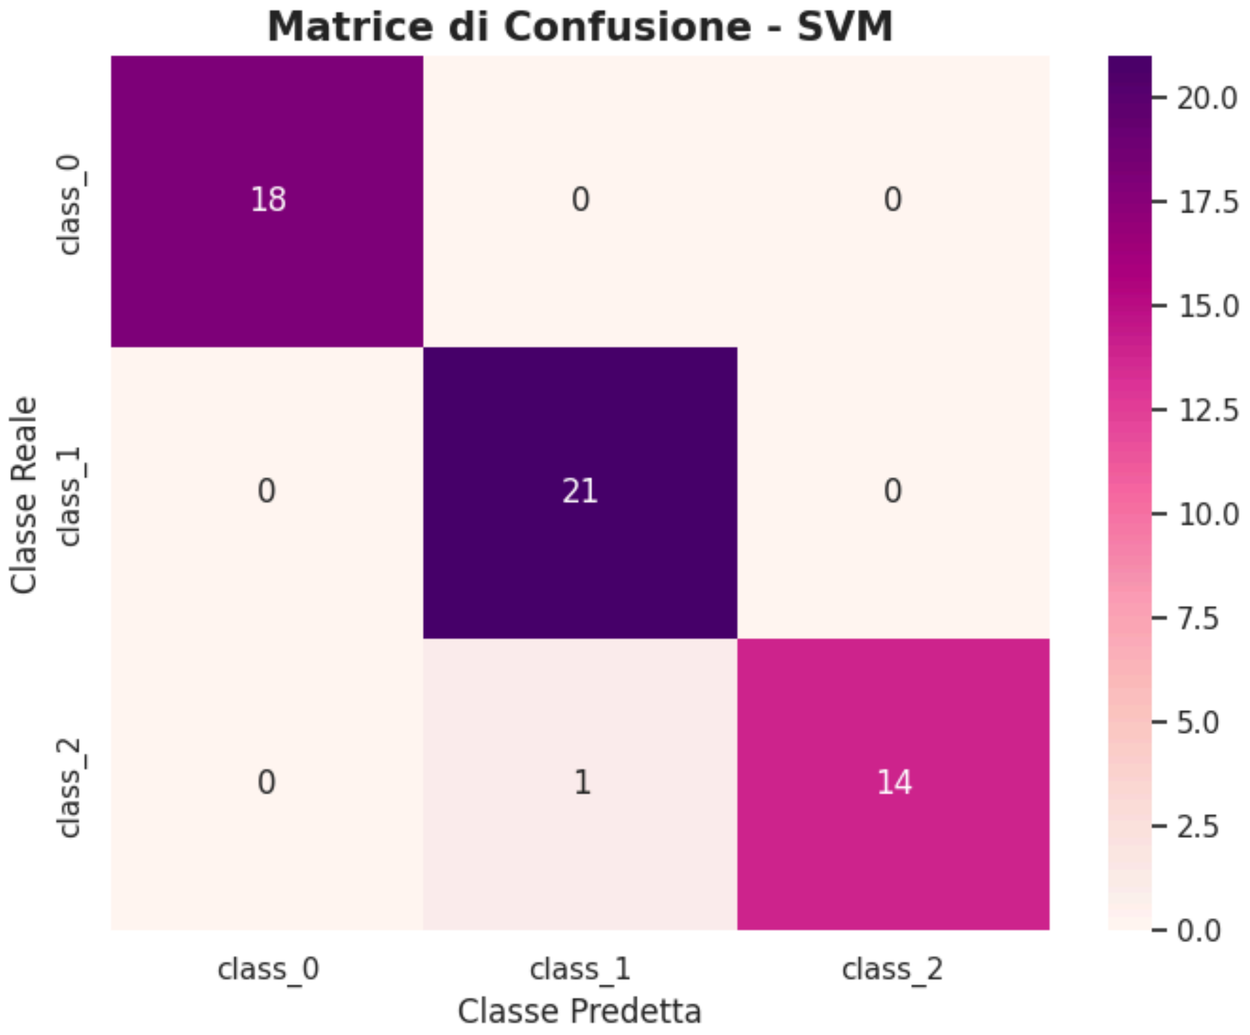

Modello B: Random Forest (RF)

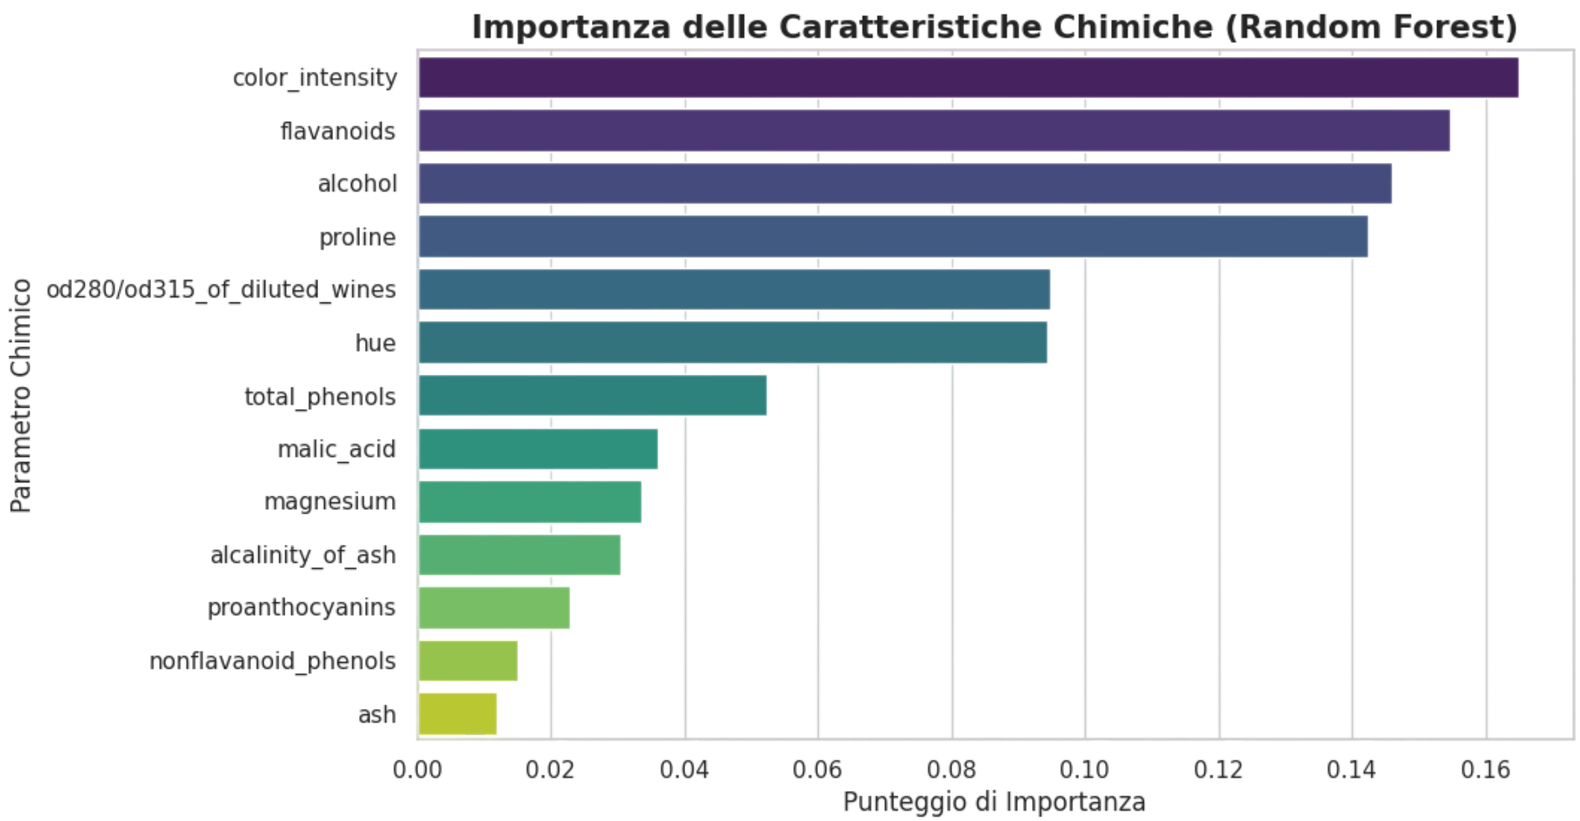

L'efficacia dell'Ensemble Learning

- **Tecnica:** Foresta di 200 alberi decisionali
- **Vantaggio:** Alta robustezza e nessuna necessità di linearità
- **Performance:** 100% di accuratezza sul test set. Nessun errore di classificazione registrato

Analisi Comparativa

La Random Forest è stata scelta come modello finale per l'azienda:

- **Perchè:** Risultati peretti sul test set e alta interpretabilità (Feature Importance)
- **Business Intelligence:** Sappiamo che l'intensità del colore è il parametro più importante per distinguere i produttori

Metrica	*Support Vector Machine (SVM)*	*Random Forest (RF)*
Accuratezza Validazione (CV)	99.2000%	97.5333%
Accuratezza Test Set	98.1481%	100.0000%
Migliori Iperparametri	C = 1, Kernel = RBF	n_estimators = 200, Gini

Simulatore

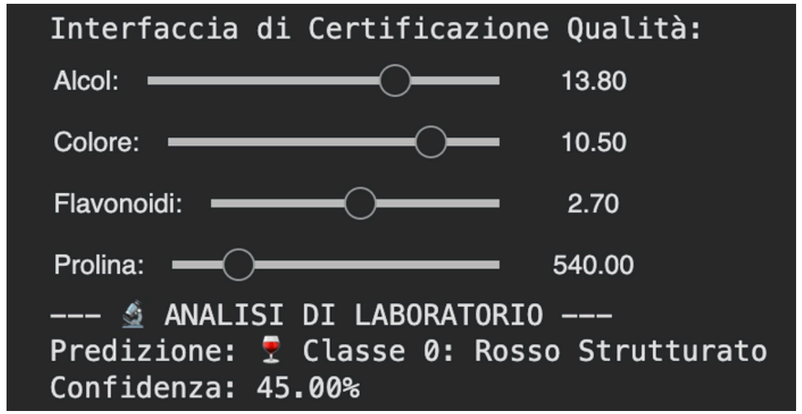

Accessibilità Operativa

In un contesto aziendale reale, chi deve prendere decisioni sulla qualità del vino spesso non ha competenze di programmazione in Python:

- **Perchè inserirlo:** Il simulatore abbatte la barriera tecnica, trasformando un complesso modello matematico in uno strumento user - friendly
- **Valore aggiunto:** Dimostra la capacità del Data Scientist di creare soluzioni “chiavi in mano” che possono essere utilizzate immediatamente da qualsiasi stakeholder aziendale tramite una semplice interfaccia grafica

Validazione e Prototipazione

Il simulatore permette di effettuare test istantanei senza dover manipolare manualmente il dataset o riscrivere righe di codice per ogni nuovo campione:

- **Perchè inserirlo:** Consente ai tecnici di laboratorio di inserire i parametri di un lotto appena analizzato e ottenere una pre-certificazione in tempo reale
- **Valore aggiunto:** Riduce drasticamente i tempi di risposta (feedback loop) tra l'analisi chimica e la classificazione, permettendo all'azienda di identificare anomalie produttive prima che il prodotto prosegua lungo la filiera

Scenari “What - If”

A differenza di un report statico, il simulatore permette di capire dinamicamente come il modello ragiona:

- **Perchè inserirlo:** Muovendo gli slider, l'utente può osservare come piccole variazioni in un parametro possano spostare la classificazione da un produttore all'altro
- **Valore aggiunto:** Questo aiuta a validare la robustezza del modello e fornisce una comprensione profonda della "zona di incertezza". È uno strumento di Decision Support che aiuta l'azienda a definire i limiti di tolleranza chimica per i propri standard di qualità.

Contatti

Telefono	331 3692727
E-mail	matteo.mallia@salesianitreviglio.it
Instagram	matteo_mallia99
Linkedin	Matteo Mallia

IL PASSAGGIO DA UN'ANALISI DI LABORATORIO STATICA A UN MODELLO PREDITTIVO DINAMICO SEGNA L'INGRESSO DELLA FILIERA VINICOLA NELL'ERA DELL'AGRICOLTURA 4.0.

CON UN'ACCURATEZZA DEL 100% E UN'INTERFACCIA OPERATIVA IMMEDIATA, SI È CREATO UN PUNTO TRA SCIENZA DEL DATO E PRODUZIONE ARTIGIANALE, DIMOSTRANDO CHE LA TECNOLOGIA È IL MIGLIOR ALLEATO PER PROTEGGERE E VALORIZZARE L'IDENTITÀ DEL NOSTRO PATRIMONIO ENOLOGICO.

Clicca qui per il notebook